

# Generazione di modelli per predire l'interesse dei clienti per l'acquisto di una polizza

Francesco Gozzoli

29/10/2021

## INTRODUZIONE

Il dataset contiene informazioni sull'interesse di clienti di una compagnia di assicurazioni per l'acquisto di polizze auto. Inizialmente le colonne che compongono il dataset sono 11 più l'ultima che è quella che identifica la classe di appartenenza delle istanze, ovvero la ground truth. Le features sono informazioni sulle persone prese in esame, in particolare:

- ID: indice identificativo dei record del dataset
- Gender: Sesso del cliente (Male/Female)
- Age: Età del cliente espressa in anni
- DrivingLicense: Possesso della patente di guida (1 in caso positivo o 0 in caso negativo)
- RegionCode: Codice della regione di residenza del cliente
- PreviouslyInsured: Indica se il cliente è già assicurato oppure no (1 in caso positivo o 0 in caso negativo)
- VehicleAge: Età del veicolo espressa in 3 categorie (<1 anno, 1-2 anni, >2 anni)
- VehicleDamage: Indica se il cliente ha fatto incidenti in passato oppure no (1 se positivo o 0 se negativo)
- AnnualPremium: Premio che il cliente paga attualmente
- PolicySalesChannel: Codice che indica il canale di comunicazione con il quale si interfaccia l'utente (Agente, Mail, Telefono, Fax)
- Vintage: Da quanto tempo il cliente è assicurato con la compagnia espresso in giorni
- Response: La ground truth che indica l'interesse del cliente, 1 se è interessato, 0 se non è interessato

Le colonne inizialmente si trovano nella situazione mostrata dalla funzione `summary`.

```
insurance <- read.csv("../insurance.csv")
summary(insurance)
```

```
##          id          Gender          Age          Driving_License
## Min.      : 1      Length:381109      Min.    :20.00      Min.    :0.0000
## 1st Qu.: 95278      Class :character      1st Qu.:25.00      1st Qu.:1.0000
## Median :190555      Mode  :character      Median :36.00      Median :1.0000
## Mean    :190555                      Mean    :38.82      Mean    :0.9979
## 3rd Qu.:285832                      3rd Qu.:49.00      3rd Qu.:1.0000
## Max.    :381109                      Max.    :85.00      Max.    :1.0000
## Region_Code Previously_Insured Vehicle_Age Vehicle_Damage
## Min.      : 0.00      Min.    :0.0000      Length:381109      Length:381109
## 1st Qu.:15.00      1st Qu.:0.0000      Class :character      Class :character
## Median :28.00      Median :0.0000      Mode  :character      Mode  :character
## Mean    :26.39      Mean    :0.4582
## 3rd Qu.:35.00      3rd Qu.:1.0000
## Max.    :52.00      Max.    :1.0000
## Annual_Premium Policy_Sales_Channel Vintage Response
## Min.      : 2630      Min.    : 1          Min.    : 10.0      Min.    :0.0000
```

```
## 1st Qu.: 24405    1st Qu.: 29          1st Qu.: 82.0    1st Qu.:0.0000
## Median : 31669    Median :133          Median :154.0    Median :0.0000
## Mean   : 30564    Mean   :112          Mean   :154.3     Mean   :0.1226
## 3rd Qu.: 39400    3rd Qu.:152          3rd Qu.:227.0    3rd Qu.:0.0000
## Max.   :540165    Max.   :163          Max.   :299.0     Max.   :1.0000
```

Il dataset è composto quindi da 12 colonne e 381109 righe

```
length(insurance[,1])
```

```
## [1] 381109
```


Uno degli aspetti più critici del dataset in analisi è lo sbilanciamento tra le classi, come si evince dal seguente piechart. Infatti le percentuali evidenziano uno sbilanciamento di 88% (334399) a favore della classe dei negativi contro il 12% (46710) della classe dei positivi

```
freq <- as.data.frame(table(insurance$Response))
colnames(freq)[1] = "Response"
freq$perc <- prop.table(freq$Freq)
print(freq)
```

```
## Response Freq perc
## 1      0 334399 0.8774366
## 2      1  46710 0.1225634
```

```
ggplot(freq, aes(x = "", y = perc, fill = Response)) +
  geom_col(color = "black") +
  coord_polar(theta = "y") +
  xlab("") +
  ylab("") +
  ggtitle("Frequenza delle classi") +
  theme(plot.title = element_text(hjust = 0.5))
```

Frequenza delle classi



## PRE-PROCESSING

Per poter essere utilizzate efficientemente, alcune colonne hanno bisogno di essere manipolate. In particolare:

- La colonna `Gender`, viene trasformata nella colonna `Male`, che ammette valori binari 0 e 1 dove 1 rappresenta il sesso maschile e 0 quello femminile.

```
insurance[which(insurance$Gender == "Male"),]$Gender = 1
insurance[which(insurance$Gender == "Female"),]$Gender = 0
colnames(insurance)[2] = "Male"
insurance$Male <- as.factor(insurance$Male)
```

- La colonna `Vehicle_Age` viene convertita da categorica ordinata a numerica. I valori utilizzati sono:

- 1 per le auto immatricolate da meno di un anno
- 0 per le auto immatricolate tra gli 1 e i 2 anni precedenti
- 1 per le auto immatricolate da più di 2 anni

```
insurance[which(insurance$Vehicle_Age == "< 1 Year"),]$Vehicle_Age <- -1
insurance[which(insurance$Vehicle_Age == "1-2 Year"),]$Vehicle_Age <- 0
insurance[which(insurance$Vehicle_Age == "> 2 Years"),]$Vehicle_Age <- 1
insurance$Vehicle_Age <- as.numeric(insurance$Vehicle_Age)
```

- La colonna `Vehicle_Damage` viene convertita da categorica nominale a factor. I valori utilizzati sono:
  - 0 per le auto che non sono mai state coinvolte in incidenti
  - 1 per le auto che sono state coinvolte in incidenti

```
insurance[which(insurance$Vehicle_Damage == "Yes"),]$Vehicle_Damage <- 1
insurance[which(insurance$Vehicle_Damage == "No"),]$Vehicle_Damage <- 0
insurance$Vehicle_Damage <- as.factor(insurance$Vehicle_Damage)
```

Le colonne categoriche e binarie restanti vengono convertite in factor

```
insurance$Driving_License <- as.factor(insurance$Driving_License)
insurance$Region_Code <- as.factor(insurance$Region_Code)
insurance$Previously_Insured <- as.factor(insurance$Previously_Insured)
insurance$Policy_Sales_Channel <- as.factor(insurance$Policy_Sales_Channel)
insurance$Response <- as.factor(insurance$Response)
```

## STATISTICHE DESCRITTIVE


Attraverso la funzione ggplot si generano i grafici che mostrano la distribuzione di frequenza delle variabili numeriche Age, Vintage e Annual\_Premium

```
library(ggplot2)
age_plot <- ggplot(insurance, aes(x=Age, fill=Response))+
  geom_histogram(alpha=0.4,position="identity")+
  xlab("Età")+
  scale_y_continuous("Numero di osservazioni") +
  guides(fill=guide_legend(title=NULL)) +
  scale_fill_discrete(labels=c("Negativi","Positivi")) +
  theme(legend.position = c(1,1),legend.justification=c(1,1))

#Frequenze Vintage
vintage_plot <- ggplot(insurance, aes( x=Vintage, fill=Response))+
  geom_histogram(alpha=0.4,position="identity")+
  xlab("Vintage")+
  scale_y_continuous("Numero di osservazioni")

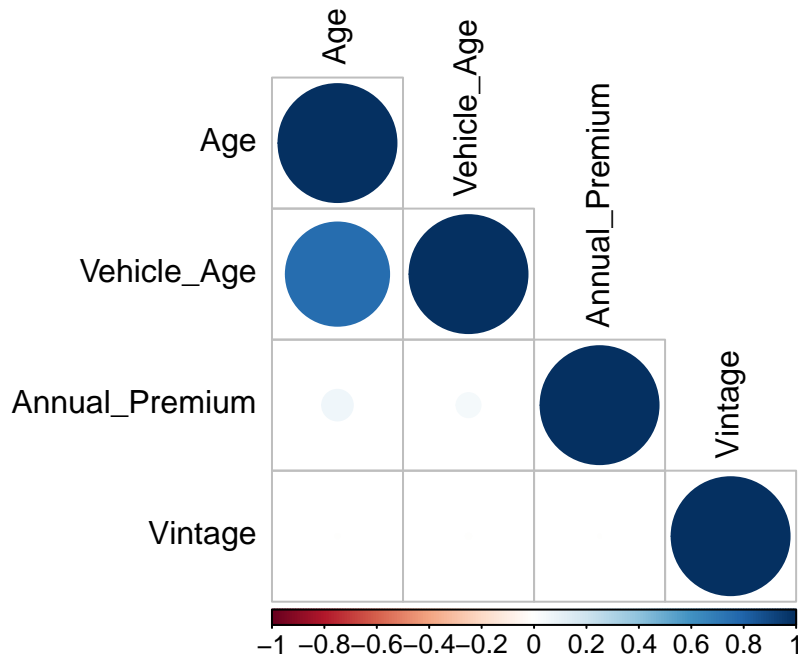
options(scipen=999)
#Frequenze annual_premium
premium_plot <- ggplot( insurance, aes( x=Annual_Premium, fill=Response))+
  geom_histogram(alpha=0.4,position="identity")+
  xlab("Premio Annuale")+
  scale_y_continuous("Numero di osservazioni") +
  scale_x_continuous(limits = c(0, 110000))

library(ggpubr)
ggarrange(age_plot, ggarrange(vintage_plot, premium_plot, ncol = 2, legend = "none"),
  nrow = 2, common.legend = T, legend = "bottom")
```




Nonostante il numero non elevato di features presenti nel dataset possiamo cercare la correlazione presente tra esse. Dalla correlation matrix si può notare che le features **Vehicle\_Age** e **Age** sono piuttosto correlate tra loro. Nonostante questo ho deciso di mantenerle entrambe poiché il vantaggio dal punto di vista computazionale è minimo, evitando così perdita di informazioni

```
library(corrplot)
correlationMatrix <- stats::cor(insurance[c(3, 7, 9, 11)])
corrplot(correlationMatrix, method="circle", type="lower", tl.col="black")
```



Per rappresentare graficamente la distribuzione dei valori delle 3 features numeriche **Age**, **Annual\_Premium** e **Vintage** e controllare la presenza di outliers si stampano i relativi boxplot. Mentre per il primo ed il terzo non si notano anomalie, per il boxplot relativo ad **Annual\_Premium** si nota che la maggioranza delle persone paga cifre molto simili tra loro e abbastanza basse, mentre un numero non trascurabile di persone paga una cifra molto più elevata per la propria assicurazione. Essendo queste istanze di numero elevato, non possiamo assumere che siano effettivamente valori anomali ed inoltre eliminarli potrebbe portare i modelli a classificare male potenziali clienti che hanno un valore alto in tale feature. Ancora, questi potenziali clienti potrebbero essere di particolare interesse proprio in virtù del loro premio particolarmente alto

```
par(mfrow=c(1,3))
boxplot(insurance$Age, main="Age")
boxplot(insurance$Annual_Premium, main="Annual_Premium")
boxplot(insurance$Vintage, main="Vintage")
```



## SEPARAZIONE STRATIFICATA

Per addestrare e validare i modelli che verranno realizzati si divide il dataset originale nei due dataset di training e testing nella classica proporzione percentuale di 70-30. Il criterio di separazione scelto è quello stratificato perchè consente di mantenere la proporzione tra le istanze della classe di maggioranza e quella di minoranza all'interno dei due dataset. È stata fatta questa scelta perchè il dataset originale è molto sbilanciato, ed in questo modo evitiamo di creare dei dataset ancora più sbilanciati

```
library(splitstackshape)
set.seed(1)
train <- as.data.frame(stratified(insurance, c('Response'), 0.7))
test <- insurance[which(!(insurance$id %in% train$id)),]
insurance <- insurance[, -1]
train <- train[, -1]
test <- test[, -1]
```

Nonostante lo sbilanciamento si prova a generare un primo modello, in particolare viene generato un albero di decisione. Per fare ciò ci si può avvalere della funzione `rpart`, che genera un albero implementando l'algoritmo CART ed utilizzando quindi l'indice di Gini come criterio per lo splitting <sup>1</sup>

## ALBERO DI DECISIONE SU DATASET SBILANCIATO

```
library(rpart)
set.seed(1)
tree <- rpart(Response~., train, method = "class", control = rpart.control(cp = 0.00001))
```

<sup>1</sup><https://cran.r-project.org/web/packages/rpart/vignettes/longintro.pdf>

```
prediction_unbalanced <- predict(tree, test, type = "class")
library(caret)
confusionMatrix(as.factor(prediction_unbalanced), as.factor(test$Response))
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction      0      1
##           0 94540 11131
##           1  5780  2882
##
##           Accuracy : 0.8521
##           95% CI : (0.85, 0.8541)
##      No Information Rate : 0.8774
##      P-Value [Acc > NIR] : 1
##
##           Kappa : 0.1771
##
##  Mcnemar's Test P-Value : <0.0000000000000002
##
##           Sensitivity : 0.9424
##           Specificity : 0.2057
##      Pos Pred Value : 0.8947
##      Neg Pred Value : 0.3327
##           Prevalence : 0.8774
##      Detection Rate : 0.8269
##      Detection Prevalence : 0.9242
##      Balanced Accuracy : 0.5740
##
##      'Positive' Class : 0
##
```

Come si può notare dalla ConfusionMatrix la classificazione non è per niente soddisfacente poichè nonostante riesca a classificare le istanze della classe di maggioranza fatica a classificare correttamente le istanze della classe di minoranza. Questo è un problema perchè oltre ad essere un punto debole del modello, l'obiettivo della classificazione è quello di massimizzare la corretta identificazione di potenziali clienti interessati piuttosto che di quelli non interessati. In generale quindi si preferisce avere un maggior tasso di falsi positivi piuttosto che di falsi negativi.

## RIBILANCIAMENTO

Alla luce delle prestazioni mostrate da questo primo modello è bene procedere ad un ribilanciamento delle classi. Per fare ciò mi sono avvalso di due tecniche:

- Tecnica di sottocampionamento casuale che consiste nel rimuovere casualmente istanze della classe di maggioranza fino ad avere un bilanciamento di circa 50-50
- Sovracampionamento effettuato attraverso SMOTE, che genera istanze sintetiche della classe di minoranza sfruttando un algoritmo di k-nearest neighbors (K = 5 nel mio caso)

```
library(unbalanced)
set.seed(1)
rem <- ubUnder(train[,1:11], train$Response, perc=14, method = "percUnder")
casual.balance.train <- data.frame(rem$X, rem$Y)
casual.balance.train$rem.Y <- NULL
names(casual.balance.train)[11] <- "Response"
```



```
table(casual.balance.train$Response)
```

```
##
##      0      1
## 32771 32697
```

Per quanto riguarda l'applicazione della tecnica di ribilanciamento SMOTE (synthetic minority oversampling technique) si è scelto un approccio non esageratamente drastico cercando quindi di mantenere un leggero sbilanciamento. Per evitare di creare un dataset enorme effettuando quindi soltanto un oversampling della classe di minoranza, ho optato per una scelta ibrida abbinando all'oversampling una rimozione casuale (undersampling) delle istanze della classe di maggioranza, questo approccio ibrido è infatti consigliato dalla documentazione ufficiale di SMOTE <sup>2</sup>. A questo scopo i parametri scelti per l'esecuzione di `ubBalance` sono:

- `percOver = 100` questo significa che l'algoritmo crea istanze sintetiche della classe di minoranza in numero pari a  $(percOver/100) * num.istanzeclasseminoranza$  delle istanze di quest'ultima
- `percUnder = 280` questo significa che l'algoritmo effettua un undersampling della classe di maggioranza mantenendone un numero pari a  $(280/100) * num.istanzesintetiche$

```
set.seed(1)
SMOTE <- ubBalance(train[,-c(11)], train[,11],type="ubSMOTE", positive = 1,
                  percOver = 100, percUnder = 280, verbose = T)
```

```
## Proportion of positives after ubSMOTE : 41.67 % of 156945 observations
```

```
SMOTE_train <- SMOTE$X
SMOTE_train$Response <- SMOTE$Y
table(SMOTE_train$Response)
```

```
##
##      0      1
## 91551 65394
```

## MODELLI DI CLASSIFICAZIONE

### ALBERI DI DECISIONE

Per prima cosa si valutano le prestazioni dell'albero di decisione applicato ai dataset bilanciati, prima il dataset bilanciato con la tecnica di sottocampionamento e dopo il dataset bilanciato con lo SMOTE

```
set.seed(1)
tree <- rpart(Response~., casual.balance.train, method = "class",
              control = rpart.control(cp = 0.00001))
prediction_casual_balance <- predict(tree, test, type = "class")
confusionMatrix(as.factor(prediction_casual_balance),as.factor(test$Response))
```

```
## Confusion Matrix and Statistics
##
##              Reference
## Prediction      0      1
##      0 70913  2746
##      1 29407 11267
##
##              Accuracy : 0.7188
##              95% CI : (0.7162, 0.7214)
##      No Information Rate : 0.8774
##      P-Value [Acc > NIR] : 1
```

---

<sup>2</sup><https://arxiv.org/pdf/1106.1813.pdf>

```

##
##           Kappa : 0.281
##
## Mcnemar's Test P-Value : <0.0000000000000002
##
##           Sensitivity : 0.7069
##           Specificity : 0.8040
##           Pos Pred Value : 0.9627
##           Neg Pred Value : 0.2770
##           Prevalence : 0.8774
##           Detection Rate : 0.6202
##           Detection Prevalence : 0.6442
##           Balanced Accuracy : 0.7555
##
##           'Positive' Class : 0
##

set.seed(1)
tree <- rpart(Response~., SMOTE_train, method = "class",
              control = rpart.control(cp = 0.0001))
prediction_smote <- predict(tree, test, type = "class")
confusionMatrix(as.factor(prediction_smote), as.factor(test$Response))


## Confusion Matrix and Statistics
##
##           Reference
## Prediction      0      1
##           0 79721  4978
##           1 20599  9035
##
##           Accuracy : 0.7763
##           95% CI : (0.7739, 0.7787)
##           No Information Rate : 0.8774
##           P-Value [Acc > NIR] : 1
##
##           Kappa : 0.297
##
## Mcnemar's Test P-Value : <0.0000000000000002
##
##           Sensitivity : 0.7947
##           Specificity : 0.6448
##           Pos Pred Value : 0.9412
##           Neg Pred Value : 0.3049
##           Prevalence : 0.8774
##           Detection Rate : 0.6973
##           Detection Prevalence : 0.7408
##           Balanced Accuracy : 0.7197
##
##           'Positive' Class : 0
##

```

Come si può notare i risultati sono migliorati molto rispetto al primo modello con dataset sbilanciato, in particolare si nota come la tecnica di undersampling fornisca prestazioni peggiori rispetto a SMOTE per quanto riguarda la sensitivity ma migliori per quanto riguarda la specificity, quest'ultima è preferibile in questo caso come già accennato prima

Per valutare le prestazioni di un classificatore binario o per confrontarne più di uno graficamente ci si affida alla curva ROC, che mettendo in relazione il tasso di veri positivi e il tasso di falsi positivi permette un'immediata valutazione dei modelli. In generale, un modello risulta essere più accurato quanto più la sua curva ROC si avvicina all'angolo superiore sinistro del grafico

```
library(pROC)
par(mfrow=c(1,1), pty = "s")
plot.roc(as.numeric(test$Response), as.numeric(prediction_unbalanced), col="red")
lines.roc(as.numeric(test$Response), as.numeric(prediction_casual_balance), col="blue")
lines.roc(as.numeric(test$Response), as.numeric(prediction_smote), col="green")
legend("bottomright", legend = c("Unbalanced", "Random Undersampling", "SMOTE"), lty=1,
      col=c("red", "blue", "green"), cex = 0.5)
```



## NAIVE BAYES

Adesso si utilizza il metodo di classificazione Naive-Bayes anche grazie al fatto che non ci sono dati mancanti. Questo metodo risulta molto rapido nell'esecuzione perchè nonostante si basi sul teorema di Bayes, il metodo Naive-Bayes fa delle semplificazioni assumendo che l'effetto di un attributo su una data classe sia indipendente dai valori degli altri attributi. Come per gli alberi di decisione si valuteranno le prestazioni prima sul dataset originale e poi per entrambi i dataset bilanciati, prima quello bilanciato con Undersampling e dopo quello bilanciato con SMOTE

```
#Naive-Bayes su dataset sbilanciato
library(e1071)
bayes_bil <- naiveBayes(Response ~ ., data = casual.balance.train)
b_prediction_unbalanced <- predict(bayes_bil, newdata = test)
confusionMatrix(as.factor(b_prediction_unbalanced), as.factor(test$Response))
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction    0    1
##           0 69269 1557
##           1 31051 12456
##
##           Accuracy : 0.7148
##           95% CI : (0.7122, 0.7174)
##       No Information Rate : 0.8774
##       P-Value [Acc > NIR] : 1
##
##           Kappa : 0.3041
##
##  McNemar's Test P-Value : <0.0000000000000002
##
##           Sensitivity : 0.6905
##           Specificity : 0.8889
##       Pos Pred Value : 0.9780
##       Neg Pred Value : 0.2863
##           Prevalence : 0.8774
##       Detection Rate : 0.6059
##       Detection Prevalence : 0.6195
##       Balanced Accuracy : 0.7897
##
##       'Positive' Class : 0
##
```

```
#Naive-Bayes su dataset bilanciato con Undersampling casuale
```

```
bayes <- naiveBayes(Response ~ ., data = train)
b_prediction_casual_balance <- predict(bayes, newdata = test)
confusionMatrix(as.factor(b_prediction_casual_balance),as.factor(test$Response))
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction    0    1
##           0 73853 3097
##           1 26467 10916
##
##           Accuracy : 0.7414
##           95% CI : (0.7389, 0.744)
##       No Information Rate : 0.8774
##       P-Value [Acc > NIR] : 1
##
##           Kappa : 0.3
##
##  McNemar's Test P-Value : <0.0000000000000002
##
##           Sensitivity : 0.7362
##           Specificity : 0.7790
##       Pos Pred Value : 0.9598
##       Neg Pred Value : 0.2920
##           Prevalence : 0.8774
##       Detection Rate : 0.6459
```

```
## Detection Prevalence : 0.6730
## Balanced Accuracy : 0.7576
##
## 'Positive' Class : 0
##

#Naive-Bayes su dataset bilanciato con SMOTE
bayes_bil <- naiveBayes(Response ~ ., data = SMOTE_train)
b_prediction_smote <- predict(bayes_bil, newdata = test)
confusionMatrix(as.factor(b_prediction_smote), as.factor(test$Response))


## Confusion Matrix and Statistics
##
##           Reference
## Prediction      0      1
##           0 66941  2054
##           1 33379 11959
##
##           Accuracy : 0.6901
##           95% CI : (0.6874, 0.6928)
## No Information Rate : 0.8774
## P-Value [Acc > NIR] : 1
##
##           Kappa : 0.2654
##
## Mcnemar's Test P-Value : <0.0000000000000002
##
##           Sensitivity : 0.6673
##           Specificity : 0.8534
##           Pos Pred Value : 0.9702
##           Neg Pred Value : 0.2638
##           Prevalence : 0.8774
##           Detection Rate : 0.5855
## Detection Prevalence : 0.6035
##           Balanced Accuracy : 0.7603
##
##           'Positive' Class : 0
##
```

A differenza degli alberi di decisione il classificatore Naive-Bayes ha le prestazioni abbastanza allineate per tutti e 3 i dataset utilizzati. In particolare, il modello addestrato col dataset sbilanciato ha prestazioni abbastanza simili per sensitivity e specificity, mentre quelli addestrati con i dataset bilanciati hanno una specificity più alta a discapito della sensitivity. Il dataset bilanciato con SMOTE restituisce delle prestazioni simili al dataset bilanciato con Undersampling casuale ma più basse in ogni circostanza. In definitiva se si vogliono prestazioni più allineate tra di loro è preferibile usare il dataset originale per la fase di training, mentre prediligendo come fatto fino ad ora la specificity il dataset bilanciato con undersampling casuale risulta il migliore

Anche in questo caso si può fare una veloce valutazione delle prestazioni dei modelli mediante l'uso della curva ROC

```
par(pty = "s")
plot.roc(as.numeric(test$Response), as.numeric(b_prediction_unbalanced), col="red")
lines.roc(as.numeric(test$Response), as.numeric(b_prediction_casual_balance), col="blue")
lines.roc(as.numeric(test$Response), as.numeric(b_prediction_smote), col="green")
legend("bottomright", legend = c("Unbalanced", "Random Undersampling", "SMOTE"), lty=1,
```

```
col=c("red", "blue", "green"), cex = 0.5)
```



## SVM


Una soluzione allo sbilanciamento alternativa alla alterazione del dataset è quella di applicare una funzione di peso che permette di dare più importanza alle istanze di una classe rispetto a quelle dell'altra. In questo caso si applica la funzione di peso al metodo di classificazione SVM, utilizzato perchè molto efficace nei problemi di classificazione binaria. Utilizzando kernel lineare la SVM separa tramite un iperpiano le istanze in classi. In particolare i pesi (parametro `weights`) utilizzati sono 1 per la classe di maggioranza e 6 per la classe di minoranza, per ottenere un peso simile tra le classi

```
weights <- c(1,6)
names(weights) <- c(0, 1)
set.seed(1)
support <- svm(formula = Response ~ ., data = train[, 1:11], kernel = "linear",
               class.weights = weights, scale = TRUE)
svm_prediction <- predict(support, newdata = test)
confusionMatrix(as.factor(svm_prediction),as.factor(test$Response))
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction    0    1
##           0 69748 1587
##           1 30572 12426
##
##           Accuracy : 0.7187
```

```
##          95% CI : (0.7161, 0.7213)
##    No Information Rate : 0.8774
##    P-Value [Acc > NIR] : 1
##
##          Kappa : 0.308
##
##    McNemar's Test P-Value : <2e-16
##
##          Sensitivity : 0.6953
##          Specificity : 0.8867
##          Pos Pred Value : 0.9778
##          Neg Pred Value : 0.2890
##          Prevalence : 0.8774
##          Detection Rate : 0.6100
##          Detection Prevalence : 0.6239
##          Balanced Accuracy : 0.7910
##
##          'Positive' Class : 0
##
```

```
par(pty = "s")
plot.roc(as.numeric(test$Response), as.numeric(svm_prediction), col="red")
```



Le prestazioni del classificatore sono buone in generale e soprattutto hanno ottima specificity, purtroppo però il metodo risulta molto costoso dal punto di vista del tempo, motivo per il quale mi sono limitato ad applicarlo ad uno solo dei dataset a disposizione

## XGBOOST

L'algoritmo XGBoost si basa sul metodo del *gradient boosting* che utilizza le derivate di secondo ordine, cioè il gradiente, per trovare il miglior modello ad albero grazie ad una esaustiva valutazione di tutte le possibili suddivisioni ad ogni passo dell'algoritmo. Viste le prestazioni del metodo SVM abbinata alla funzione dei pesi anche l'algoritmo XGBoost si applica allo stesso modo

```
library(xgboost)
library(Matrix)

xgb_preprocess <- function(df)
{
  df.xgb <- df[,c(1,2,3,5,6,7,8,10,11)]
  df.xgb$Male <- as.numeric(as.character(df.xgb$Male))
  df.xgb$Driving_License <- as.numeric(as.character(df.xgb$Driving_License))
  df.xgb$Vehicle_Damage <- as.numeric(as.character(df.xgb$Vehicle_Damage))
  df.xgb$Previously_Insured <- as.numeric(as.character(df.xgb$Previously_Insured))
  df.xgb$Response <- as.numeric(as.character(df.xgb$Response))
  df.xgb$Age <- as.numeric(df.xgb$Age)
  df.xgb$Vintage <- as.numeric(df.xgb$Vintage)
  df.xgb <- as.matrix(df.xgb)
  return(df.xgb)
}

train.xgb = xgb_preprocess(train)
weight <- ifelse(train$Response==1, 6,1)
set.seed(1)
bst <- xgboost(data = train.xgb[,-9], label = train.xgb[,9],
               nthread = -1, nrounds = 100, weight = weight, verbose=0)

test.xgb = xgb_preprocess(test)
test.xgb <- test.xgb[,-9]


xgb_prediction <- predict(bst, test.xgb)
xgb_prediction <- as.numeric(xgb_prediction > 0.5)
confusionMatrix(as.factor(xgb_prediction),as.factor(test$Response))

## Confusion Matrix and Statistics
##
##              Reference
## Prediction      0      1
##              0 69417 1538
##              1 30903 12475
##
##              Accuracy : 0.7163
##              95% CI : (0.7136, 0.7189)
##              No Information Rate : 0.8774
##              P-Value [Acc > NIR] : 1
##
##              Kappa : 0.3062
##
##              Mcnemar's Test P-Value : <0.0000000000000002
##
##              Sensitivity : 0.6920
##              Specificity : 0.8902
##              Pos Pred Value : 0.9783
```



```
##          Neg Pred Value : 0.2876
##          Prevalence : 0.8774
##          Detection Rate : 0.6071
##          Detection Prevalence : 0.6206
##          Balanced Accuracy : 0.7911
##
##          'Positive' Class : 0
##
```

```
par(pty = "s")
plot.roc(as.numeric(test$Response), as.numeric(xgb_prediction), col="red")
```



Le prestazioni sono allineate a quelle dell'SVM, ma a differenza di quest'ultimo i tempi di esecuzioni sono estremamente rapidi, questa differenza sostanziale rende preferibile l'XGBoost

## CONCLUSIONI

Come già detto in precedenza la priorità nelle prestazioni è stata data alla specificity, senza ovviamente trascurare troppo la sensitivity, e con un occhio di riguardo alla velocità di esecuzione di ogni modello. Si nota che l'unico modello a funzionare egregiamente con il dataset di training fortemente sbilanciato è il Naive-Bayes; per gli alberi di decisione invece le manipolazioni effettuate sono risultate molto efficaci nel migliorare le prestazioni. Mentre l'SVM come prestazioni è risultato ottimo ma abbinato a tempi di esecuzione estremamente lunghi rispetto agli altri algoritmi impiegati (dell'ordine delle ore), il Boosting è risultato altrettanto ottimo quanto l'SVM impiegando però brevissimo tempo per l'esecuzione. Concludendo, se l'obiettivo come in questo caso è quello di trovare più clienti interessati possibili, è bene massimizzare la specificity usando un metodo che non richieda troppo tempo per l'esecuzione, allora il migliore risulta essere il modello addestrato con XGBoost. Se invece si ritenesse l'XGBoost troppo specificity-oriented, si può

optare per l'albero generato tramite l'algoritmo CART addestrato sul dataset ribilanciato con la tecnica del sottocampionamento casuale